

Exploración de Datos y Selección del Modelo

1 Objetivo


Analizar los datos obtenidos mediante web scraping y la API de EDAMAM para comprender su estructura y seleccionar los modelos adecuados para la detección de ingredientes y la recomendación de recetas.

2 Exploración de Datos


Se realizó un análisis exploratorio de datos (EDA) sobre la base de datos de recetas e ingredientes. A continuación, se presentan los hallazgos más relevantes:

2.1 Distribución de Calorías en las Recetas

- La mayoría de las recetas contienen menos de 1000 calorías.
- Se detectaron **outliers**, algunos de los cuales corresponden a errores humanos en la redacción de recetas, donde las raciones fueron mal especificadas.
- Se identificaron problemas en el parseo de ingredientes al traducirlos al inglés para EDAMAM, como el caso de los granos de maíz, que pasaron de "50 granos de maíz" a "50 mazorcas de maíz", inflando las calorías calculadas.



(a) Histograma de distribución de calorías en recetas



(b) Boxplot con detección de outliers en calorías

Figure 1: Análisis de distribución de calorías en las recetas

2.2 Frecuencia de uso de ingredientes

En promedio, cada receta contiene **8.74 ingredientes**

Se realizó un countplot que permitió detectar los ingredientes más comunes en las recetas. Como era de esperar, más que ingredientes los elementos con más apariciones son los **condimentos**, como la sal, el aceite de oliva o la pimienta.

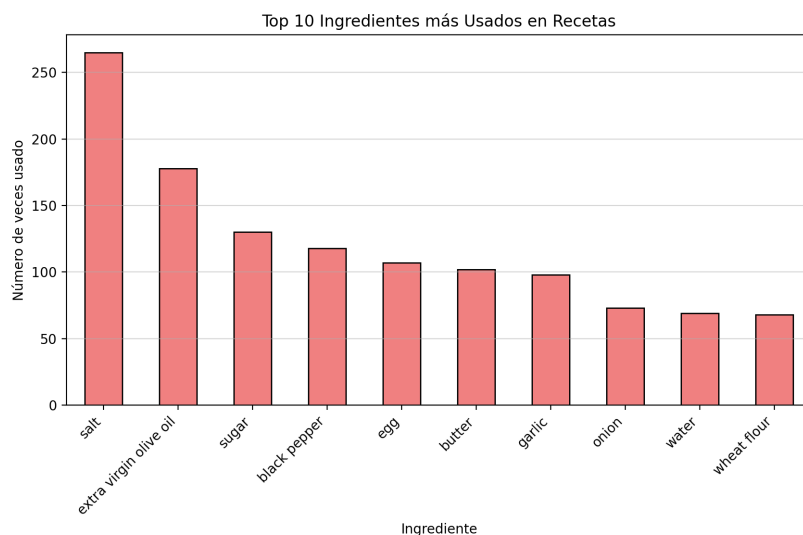


Figure 2: Ingredientes más comunes

2.3 Relación entre Macronutrientes

- Se generó un heatmap con la correlación entre macronutrientes.
- Se confirmó que las calorías están mayormente influenciadas por las grasas, lo cual es esperado dado que las grasas aportan más calorías por gramo en comparación con carbohidratos y proteínas.
- Se observó una relación inesperada: los carbohidratos tienen una correlación más fuerte con la fibra que con los azúcares. Esto podría deberse a que muchas recetas ricas en carbohidratos provienen de alimentos integrales o vegetales, que contienen un mayor porcentaje de fibra en comparación con productos refinados que presentan mayor cantidad de azúcares.

3 Selección del Modelo

Para la detección de ingredientes en imágenes, se eligió **Grounding DINO**, un modelo preentrenado especializado en segmentación y detección de objetos.




Figure 3: Heatmap de la correlación entre macronutrientes

Justificación

- No es necesario un entrenamiento desde cero, lo que ahorra tiempo y recursos computacionales.
- Permite la detección de ingredientes sin requerir etiquetas de entrenamiento específicas.
- Puede integrarse en una aplicación de recomendación de recetas basada en imágenes.
- **Es un modelo de código abierto**, lo que garantiza mayor privacidad y control sobre los datos procesados, evitando que la información de los usuarios se filtre a servidores externos.
- No depende de servicios externos como OpenAI o Perplexity, lo que permite un mayor control sobre la disponibilidad y rendimiento del sistema sin estar sujeto a latencias o restricciones de API de terceros.
- A diferencia de otros modelos como CLIP, éste permite obtener los encuadres de la identificación de categorías en las imágenes, útil para visualizar el correcto funcionamiento del modelo.

Además, se implementó un **sistema de recomendación de recetas basado en NLP**, utilizando **TF-IDF** para calcular la relevancia de los ingredientes.

Justificación

- **TF-IDF** penaliza los ingredientes más comunes, permitiendo que las recomendaciones prioricen recetas con ingredientes más específicos y difer-

enciadores.

- Se complementa con un sistema de **matching bidireccional**, que favorece recetas que pueden prepararse exclusivamente con los ingredientes proporcionados, evitando sesgos hacia recetas con listas de ingredientes más largas.

4 Prueba del Modelo Inicial

Dado que **Grounding DINO** no requiere entrenamiento desde cero, la evaluación se centró en el rendimiento de detección con el dataset disponible.

4.1 Estrategia de Evaluación

- **Evaluación Cualitativa:** Comparación visual entre predicciones del modelo y etiquetas reales.
- Se observó que el modelo tiene un buen acierto en ingredientes más comunes, probablemente debido a que el dataset usado para entrenarlo originalmente contenía mayor representación de estos elementos.
- **Métricas Cuantitativas** no fueron obtenidas en esta fase.




Figure 4: Ejemplo de detección usando el modelo GroundingDINO

En cuanto al **sistema de recomendación**, no existen métricas estandarizadas para evaluar la calidad de una recomendación. No obstante, la combinación de TF-IDF con el matching bidireccional permite mejorar la precisión en sugerencias personalizadas y evitar recomendaciones sesgadas hacia recetas más extensas.

5 Conclusiones y Próximos Pasos

Este análisis exploratorio y la selección de modelos permiten establecer una base para la detección de ingredientes en imágenes y la recomendación optimizada de recetas. Como pasos a futuro se proponen:

- Usar el dataset COCO para realizar **fine-tuning** en plataformas cloud con GPUs externas.
- Evaluar si un modelo ajustado mejora la detección de ingredientes en condiciones reales.